jamk.fi

Harjoitukset

Koneoppiminen, Syksy 2020

Tapani Alastalo
M1475

Jyväskylän ammattikorkeakoulu
JAMK University of Applied Sciences

Sisältö

jamk.fi

1 Tehtävä 1 Lineaarinen regressio

a)

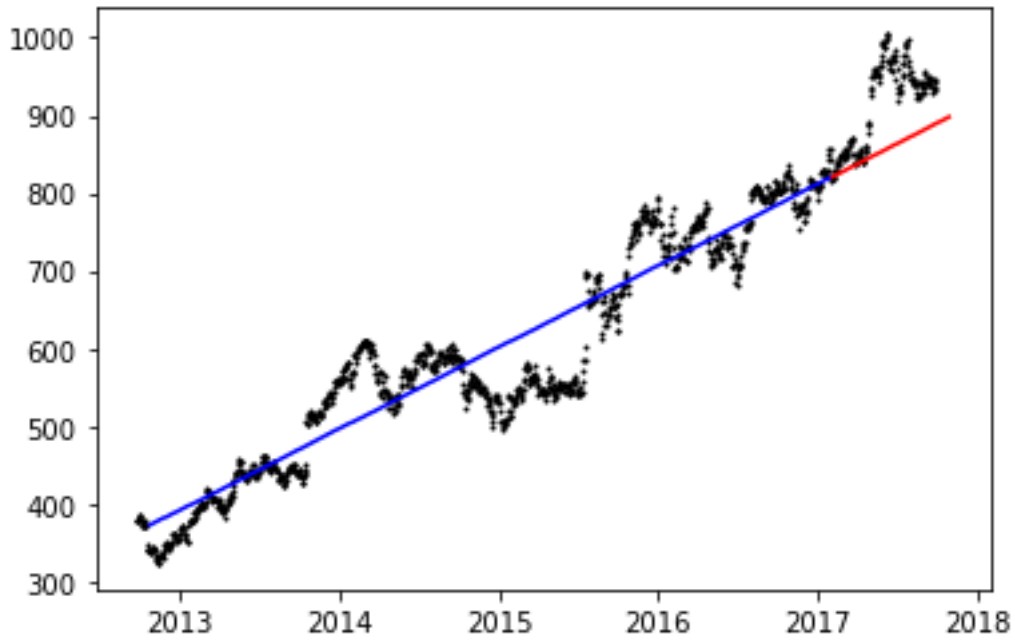

Ennusteen keskivirhe testidatassa on 70

b)

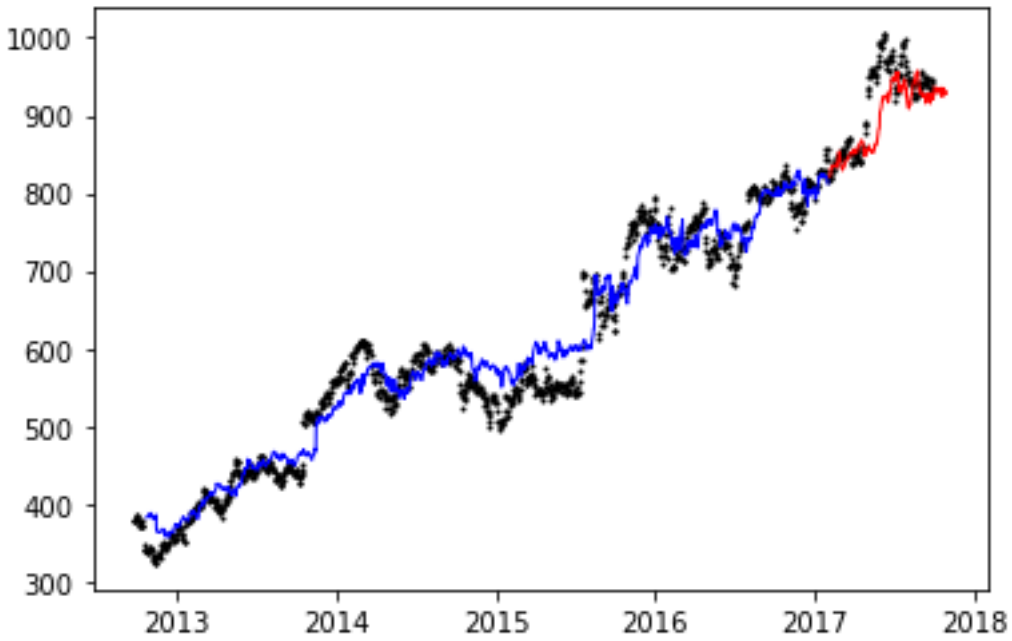

Ennusteen keskivirhe testidatassa on 35

1.1 Lähdekoodit

```
import pandas as pd
import numpy as np
from sklearn import linear_model
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error

df = pd.read_csv('data/Google_Stock_Price.csv')
df['Date'] = pd.to_datetime(df['Date'])
df['Time'] = df.apply(lambda row: len(df) - row.name, axis=1)
df['CloseFuture'] = df['Close'].shift(30)


df_test = df[:185]
df_train = df[185:]

X = np.array(df_train[['Time', 'Close']])
y = np.array(df_train['CloseFuture'])


model = linear_model.LinearRegression()
model.fit(X, y)
ennuste_train = model.predict(X)
```

```
df_train['Ennuste'] = ennuste_train


X_test = np.array(df_test[['Time', 'Close']])
ennuste_test = model.predict(X_test)
df_test['Ennuste'] = ennuste_test


plt.scatter(df['Date'].values, df['Close'].values, color='black', s=1)
plt.plot((df_train['Date'] + pd.DateOffset(days=30)).values, df_train['Ennuste'].values,
color='blue')
plt.plot((df_test['Date'] + pd.DateOffset(days=30)).values, df_test['Ennuste'].values,
color='red')

plt.show()

df_validation = df_test.dropna()

print("Ennusteen keskivirhe test datassa on %.f" % mean_absolute_error(df_valida-
tion['CloseFuture'], df_validation['Ennuste']))
```

2 Tehtävä 2

a) 7 päivän ennuste tulevaisuuteen

Ennusteen keskivirhe opetusdatassa on 16

Ennusteen keskivirhe testidatassa on 20

b) 60 päivän ennuste tulevaisuuteen

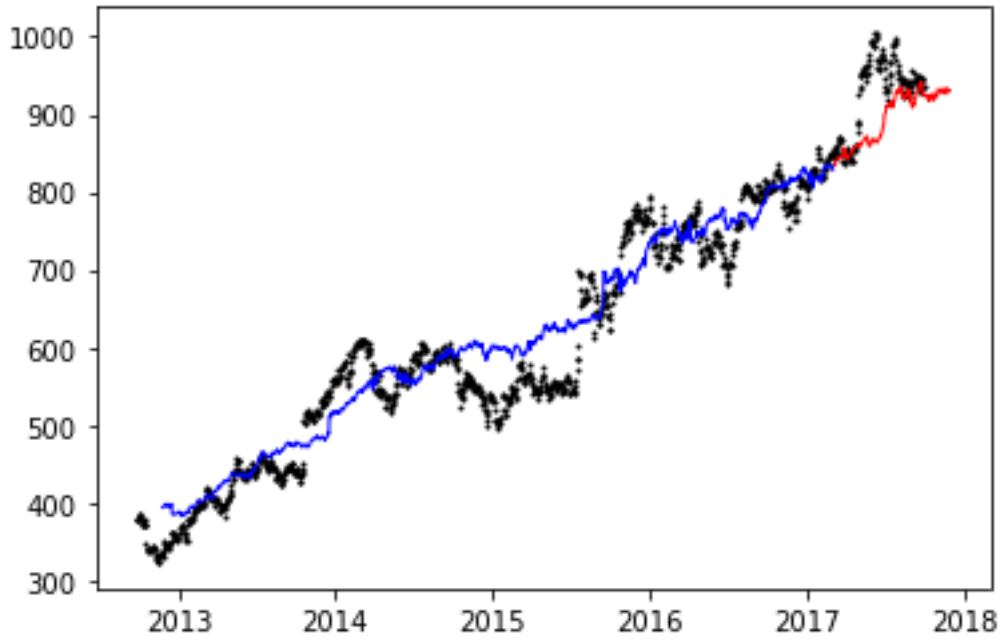

Ennusteen keskivirhe opetusdatassa on 34

Ennusteen keskivirhe testidatassa on 60

2.1 Lähdekoodit

```
import pandas as pd
import numpy as np
from sklearn import linear_model
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error

days_to_forecast = 60

df = pd.read_csv('data/Google_Stock_Price.csv')
df['Date'] = pd.to_datetime(df['Date'])
```

```
df['Time'] = df.apply(lambda row: len(df) - row.name, axis=1)
df['CloseFuture'] = df['Close'].shift(days_to_forecast)


df_test = df[:185]
df_train = df[185:]

X = np.array(df_train[['Time', 'Close']])
y = np.array(df_train['CloseFuture'])


model = linear_model.LinearRegression()
model.fit(X, y)
ennuste_train = model.predict(X)
df_train['Ennuste'] = ennuste_train


X_test = np.array(df_test[['Time', 'Close']])
ennuste_test = model.predict(X_test)
df_test['Ennuste'] = ennuste_test


plt.scatter(df['Date'].values, df['Close'].values, color='black', s=1)
plt.plot((df_train['Date'] + pd.DateOffset(days=days_to_forecast)).values,
df_train['Ennuste'].values, color='blue')
plt.plot((df_test['Date'] + pd.DateOffset(days=days_to_forecast)).values, df_test['En-
nuste'].values, color='red')

plt.show()

df_train_validation = df_train.dropna()
df_test_validation = df_test.dropna()

print("Ennusteen keskivirhe opetus datassa on %.f" % mean_absolute_er-
ror(df_train_validation['CloseFuture'], df_train_validation['Ennuste']))
print("Ennusteen keskivirhe test datassa on %.f" % mean_absolute_er-

ror(df_test_validation['CloseFuture'], df_test_validation['Ennuste']))
```

3 Tehtävä 3

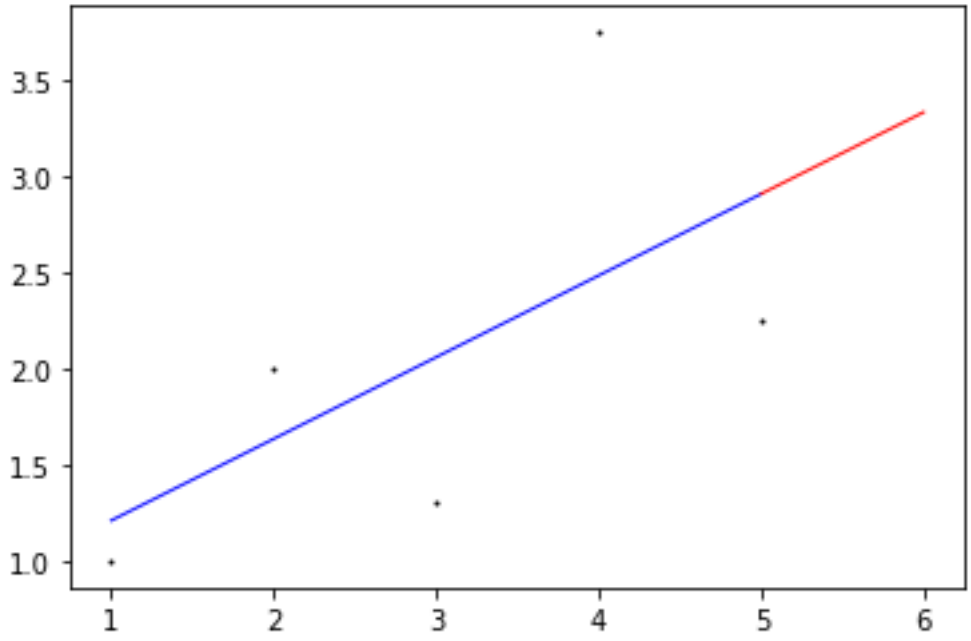

Index	X	Y	Ennuste
0	1	1	1.21
1	2	2	1.635
2	3	1.3	2.06
3	4	3.75	2.485
4	5	2.25	2.91
5	6	nan	3.335

3.1 Lähdekoodi

```
import pandas as pd
import numpy as np
from sklearn import linear_model
import matplotlib.pyplot as plt

data = [[1.00,1.00],[2.00,2.00],[3.00,1.30],[4.00,3.75],[5.00,2.25]] #,[6.00, None]]
df = pd.DataFrame(data, columns=['X', 'Y'])

df_train = df[:]
```

```
df_test = df[4:]

df_test = df_test.append({'X': 6.00}, ignore_index=True)
#df_train = df[:6]
#df_test = df[4:]

X = np.array(df_train['X'])
X = X.reshape(-1,1) # vain jos yksiulotteinen taulukko
y = np.array(df_train['Y'])

model = linear_model.LinearRegression()
model.fit(X, y)
df_train['Ennuste'] = model.predict(X)

X_test = np.array(df_test['X'])
X_test = X_test.reshape(-1,1) # vain jos yksiulotteinen taulukko
df_test['Ennuste'] = model.predict(X_test)

plt.scatter(df['X'].values, df['Y'].values, color='black', s=1)
plt.plot(df_train['X'].values, df_train['Ennuste'].values, color='blue', linewidth=1)
plt.plot(df_test['X'].values, df_test['Ennuste'].values, color='red', linewidth=1)

plt.show()

print('Mallin kertoimet ovat \n', model.coef_, model.intercept_)
df_results = df_train.append(df_test.iloc[1:], ignore_index = True)
```

4 Tehtävät 4 Neuroverkot

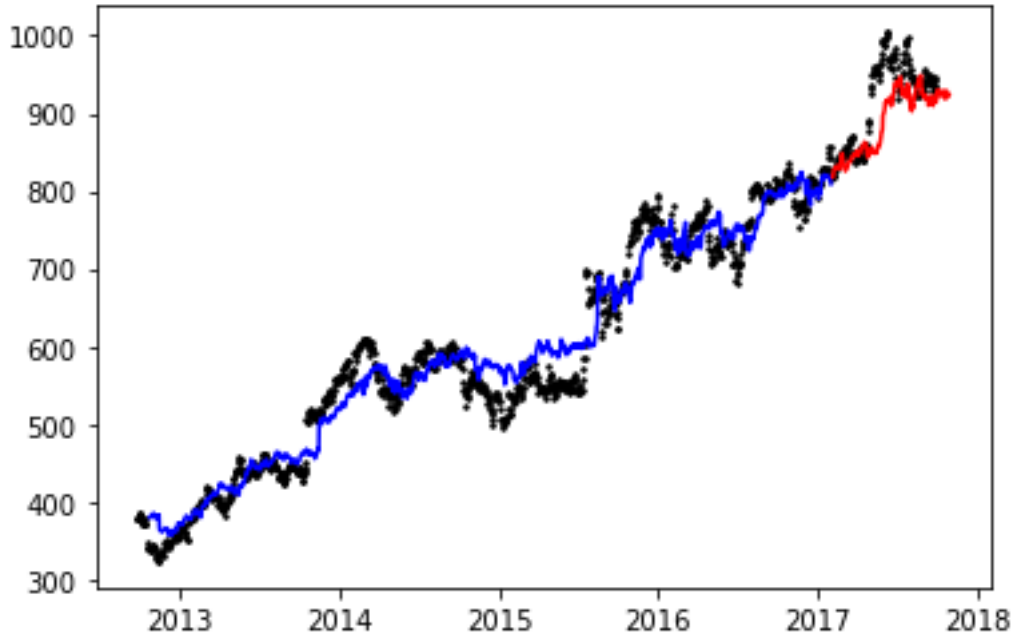

Ennusteen keskivirhe opetusdatassa on 30

Ennusteen keskivirhe testidatassa on 40

4.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error
import tensorflow as tf
from tensorflow import keras
from sklearn import preprocessing

days_to_forecast = 30

df = pd.read_csv('data/Google_Stock_Price.csv')
df['Date'] = pd.to_datetime(df['Date'])
df['Time'] = df.apply(lambda row: len(df) - row.name, axis=1)
df['CloseFuture'] = df['Close'].shift(days_to_forecast)
```

```
df_train = df[:185]
df_test = df[185:]

X = np.array(df_train[['Time', 'Close']])
scaler = preprocessing.MinMaxScaler()
X_scaled = scaler.fit_transform(X)

y = np.array(df_train['CloseFuture'])

# luodaan sequential tyyppinen neuroverkkomalli
model = tf.keras.Sequential([
   # määritellään neuroverkon piilotettu kerros. 10 neuronia (2 inputs), activation
funktio = rectified lineaarifunction, input kerros (input_shape) = input arvojen
lukumäärä
   keras.layers.Dense(10, activation='relu', input_shape=(2,)),
   # 2. piilotettu kerros
   keras.layers.Dense(10, activation='relu'),
   # mallin output kerros. 1 ulostulo (output). Ei aktivointifunktiota # ,
activation='softmax'
   keras.layers.Dense(1)])

# optimointialgoritmi Adam algoritmi (learning rate=0.001).
model.compile(optimizer=keras.optimizers.Adam(learning_rate=0.001), #'adam',
#tf.train.AdamOptimizer(0.001),
          loss='mse', #'categorical_crossentropy',
          metrics=['mae']) # ['accuracy'])

# epochs = kuinka monta kertaa opetusdata käydään läpi training vaiheessa
(painotus), batch_size = kuinka monen data rivin jälkeen painokertoimia päivitetään
(oppiminen)
model.fit(X_scaled, y, epochs = 100, batch_size = 10)
ennuste_train = model.predict(X_scaled)
df_train['Ennuste'] = ennuste_train

X_test = np.array(df_test[['Time', 'Close']])
X_testscaled = scaler.transform(X_test)
ennuste_test = model.predict(X_testscaled)
df_test['Ennuste'] = ennuste_test

plt.scatter(df['Date'].values, df['Close'].values, color='black', s=2)
plt.plot((df_train['Date'] + pd.DateOffset(days=30)).values, df_train['Ennuste'].values,
color='blue')
plt.plot((df_test['Date'] + pd.DateOffset(days=30)).values, df_test['Ennuste'].values,
color='red')
plt.show()
```

```
df_train_validation = df_train.dropna()
df_test_validation = df_test.dropna()
print("Ennusteen keskivirhe opetusdatassa on %.f" %
    mean_absolute_error(df_train_validation['CloseFuture'], df_train_validation['En-
nuste']))
print("Ennusteen keskivirhe testidatassa on %.f" %
    mean_absolute_error(df_test_validation['CloseFuture'], df_test_validation['En-
nuste']))
```

5 Tehtävä 5

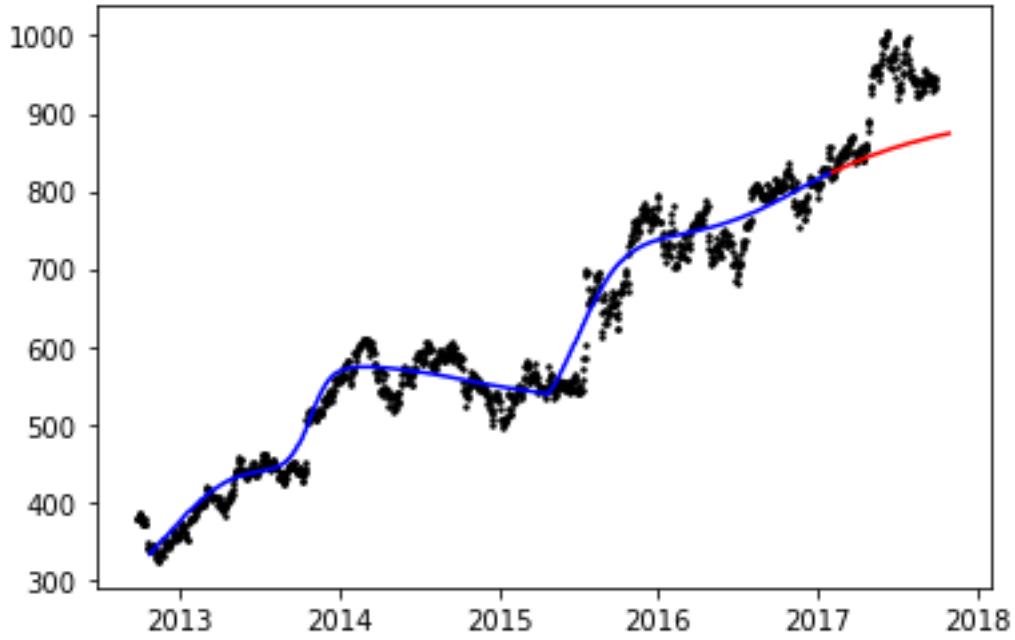

Ennusteen keskivirhe opetusdatassa on 19

Ennusteen keskivirhe testidatassa on 74

5.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error
import tensorflow as tf
```

```
from tensorflow import keras
from sklearn import preprocessing

days_to_forecast = 30

df = pd.read_csv('data/Google_Stock_Price.csv')
df['Date'] = pd.to_datetime(df['Date'])
df['Time'] = df.apply(lambda row: len(df) - row.name, axis=1)
df['CloseFuture'] = df['Close'].shift(days_to_forecast)


df_train = df[:185]
df_test = df[185:]

X = np.array(df_train[['Time']])
X = X.reshape(-1,1)
scaler = preprocessing.MinMaxScaler()
X_scaled = scaler.fit_transform(X)

y = np.array(df_train['CloseFuture'])

# luodaan sequential tyyppinen neuroverkkomalli
model = tf.keras.Sequential([
   # määritellään neuroverkon piilotettu kerros. 10 neuronia (1 input), activation
funktio = sigmoid, input kerros (input_shape) = input arvojen lukumäärä
   keras.layers.Dense(20, activation='sigmoid', input_shape=(1,)),
   # 2. piilotettu kerros
   keras.layers.Dense(20, activation='sigmoid'),
   # 3. piilotettu kerros
   keras.layers.Dense(20, activation='relu'),
   # mallin output kerros. 1 ulostulo (output). Ei aktivointifunktiota # ,
activation='softmax'
   keras.layers.Dense(1)])

# optimointialgoritmi Adam algoritmi (learning rate=0.001).
model.compile(optimizer=keras.optimizers.Adam(learning_rate=0.01), #'adam',
#tf.train.AdamOptimizer(0.001),
          loss='mse', #'categorical_crossentropy',
          metrics=['mae']) # ['accuracy'])

# epochs = kuinka monta kertaa opetusdata käydään läpi training vaiheessa
(painotus), batch_size = kuinka monen data rivin jälkeen painokertoimia päivitetään
(oppiminen)
model.fit(X_scaled, y, epochs = 100, batch_size = 10)
ennuste_train = model.predict(X_scaled)
df_train['Ennuste'] = ennuste_train
```

```
X_test = np.array(df_test[['Time']])
X_test = X_test.reshape(-1,1)
X_testscaled = scaler.transform(X_test)
ennuste_test = model.predict(X_testscaled)
df_test['Ennuste'] = ennuste_test

plt.scatter(df['Date'].values, df['Close'].values, color='black', s=2)
plt.plot((df_train['Date'] + pd.DateOffset(days=30)).values, df_train['Ennuste'].values,
color='blue')
plt.plot((df_test['Date'] + pd.DateOffset(days=30)).values, df_test['Ennuste'].values,
color='red')
plt.show()


df_train_validation = df_train.dropna()
df_test_validation = df_test.dropna()
print("Ennusteen keskivirhe opetusdatassa on %.f" %
    mean_absolute_error(df_train_validation['CloseFuture'], df_train_validation['En-
nuste']))
print("Ennusteen keskivirhe testidatassa on %.f" %
    mean_absolute_error(df_test_validation['CloseFuture'], df_test_validation['En-
nuste']))ss
```

6 Tehtävä 6

a) Lineaarista regressiomallia, jonka input-muuttujana on pelkkä aika.

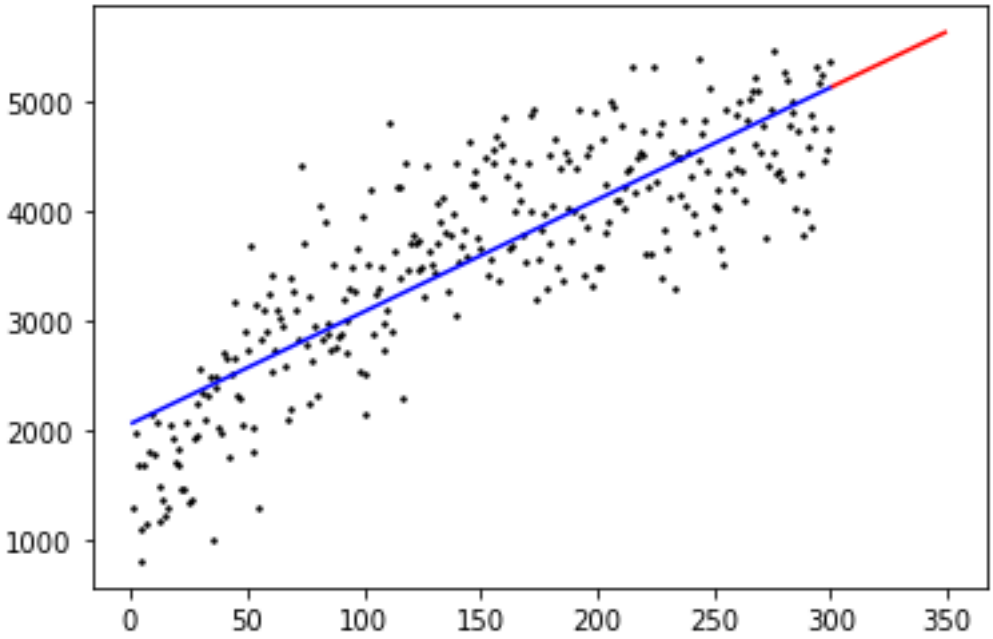

Ennusteen keskivirhe opetusdatassa on 452

6.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error
from sklearn import linear_model

df = pd.read_csv('data/Kysynta.csv', sep=';', encoding='latin_1')
print(df)

df_train = df[:300]
df_test = df[300:]

for i in range(301, 350):
    df_test = df_test.append({'Päivä': i}, ignore_index=True)

X = np.array(df_train[['Päivä']])
X = X.reshape(-1,1)

y = np.array(df_train['Kysyntä'])

model = linear_model.LinearRegression()
model.fit(X, y)
```

```
ennuste_train = model.predict(X)
df_train['Ennuste'] = ennuste_train

X_test = np.array(df_test[['Päivä']])
X_test = X_test.reshape(-1,1)
ennuste_test = model.predict(X_test)
df_test['Ennuste'] = ennuste_test

plt.scatter(df['Päivä'].values, df['Kysyntä'].values, color='black', s=2)
plt.plot((df_train['Päivä']).values, df_train['Ennuste'].values, color='blue')
plt.plot((df_test['Päivä']).values, df_test['Ennuste'].values, color='red')
plt.show()


df_train_validation = df_train.dropna()
df_test_validation = df_test.dropna()
print("Ennusteen keskivirhe opetusdatassa on %.f" %
    mean_absolute_error(df_train_validation['Kysyntä'], df_train_validation['En-
nuste']))
```

b) MLP-neuroverkkoa, jonka input-muuttujana on pelkkä aika.

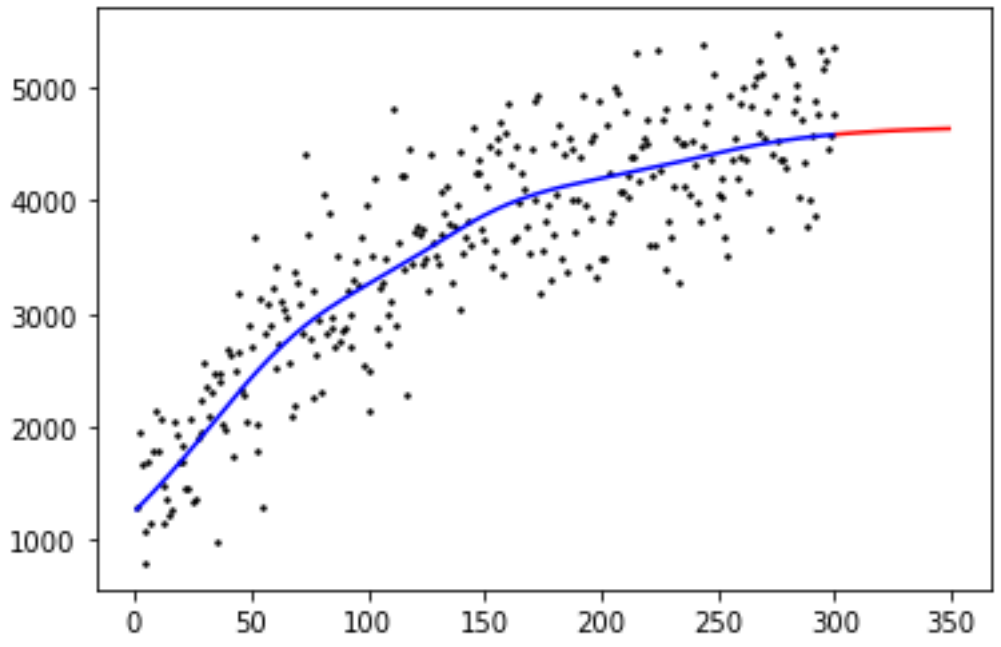

Ennusteen keskivirhe opetusdatassa on 405

Ennusteen keskivirhe testidatassa on 407

6.2 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error
import tensorflow as tf
from tensorflow import keras
from sklearn import preprocessing

df = pd.read_csv('data/Kysynta.csv', sep=';', encoding='latin_1')
print(df)

df_train = df[:300]
df_test = df[300:]

for i in range(301, 350):
   df_test = df_test.append({'Päivä': i}, ignore_index=True)

X = np.array(df_train[['Päivä']])
X = X.reshape(-1,1)
scaler = preprocessing.MinMaxScaler()
X_scaled = scaler.fit_transform(X)

y = np.array(df_train['Kysyntä'])

# luodaan sequential tyyppinen neuroverkkomalli
model = tf.keras.Sequential([
   # määritellään neuroverkon piilotettu kerros. 10 neuronia (1 input), activation
funktio = sigmoid, input kerros (input_shape) = input arvojen lukumäärä
   keras.layers.Dense(20, activation='sigmoid', input_shape=(1,)),
   # 2. piilotettu kerros
   keras.layers.Dense(20, activation='tanh'),
   # 3. piilotettu kerros
   keras.layers.Dense(20, activation='relu'),
   # mallin output kerros. 1 ulostulo (output). Ei aktivointifunktiota # ,
activation='softmax'
   keras.layers.Dense(1)])

# optimointialgoritmi Adam algoritmi (learning rate=0.001).
model.compile(optimizer=keras.optimizers.Adam(learning_rate=0.01),
          loss='mse',
          metrics=['mae'])
```

```
# epochs = kuinka monta kertaa opetusdata käydään läpi training vaiheessa
(painotus), batch_size = kuinka monen data rivin jälkeen painokertoimia päivitetään
(oppiminen)
model.fit(X_scaled, y, epochs = 100, batch_size = 10)
ennuste_train = model.predict(X_scaled)
df_train['Ennuste'] = ennuste_train

X_test = np.array(df_test[['Päivä']])
X_test = X_test.reshape(-1,1)
X_testscaled = scaler.transform(X_test)
ennuste_test = model.predict(X_testscaled)
df_test['Ennuste'] = ennuste_test

plt.scatter(df['Päivä'].values, df['Kysyntä'].values, color='black', s=2)
plt.plot((df_train['Päivä']).values, df_train['Ennuste'].values, color='blue')
plt.plot((df_test['Päivä']).values, df_test['Ennuste'].values, color='red')
plt.show()


df_train_validation = df_train.dropna()
df_test_validation = df_test.dropna()
print("Ennusteen keskivirhe opetusdatassa on %.f" %
    mean_absolute_error(df_train_validation['Kysyntä'], df_train_validation['En-
nuste']))
```

7 Tehtävä 7

Index	fruit_name	fruit_subtype	mass	width	height	olor_scor	fruit_code	LRennuste	VMennust	NNennust
0	apple	granny_smith	192	8.4	7.3	0.55	0	0	0	0
1	apple	granny_smith	180	8	6.8	0.59	0	0	0	0
2	apple	granny_smith	176	7.4	7.2	0.6	0	3	0	0
3	mandarin	mandarin	86	6.2	4.7	0.8	2	2	2	2
4	mandarin	mandarin	84	6	4.6	0.79	2	2	2	2
5	mandarin	mandarin	80	5.8	4.3	0.77	2	2	2	2
6	mandarin	mandarin	80	5.9	4.3	0.81	2	2	2	2
7	mandarin	mandarin	76	5.8	4	0.81	2	2	2	2
8	apple	braeburn	178	7.1	7.8	0.92	0	3	0	0
9	apple	braeburn	172	7.4	7	0.89	0	0	0	0
10	apple	braeburn	166	6.9	7.3	0.93	0	0	0	0
11	apple	braeburn	172	7.1	7.6	0.92	0	0	0	0
12	apple	braeburn	154	7	7.1	0.88	0	0	0	0
13	apple	golden_delicious	164	7.3	7.7	0.7	0	3	3	0
14	apple	golden_delicious	152	7.6	7.3	0.69	0	0	0	0
15	apple	golden_delicious	156	7.7	7.1	0.69	0	0	0	0

Ennusteen keskivirhe logistisella regressiolla on 0.881.

Ennusteen keskivirhe SVM luokittelulla on 0.966.

Ennusteen keskivirhe K-Lähimmännaapurin luokittelulla on 0.983.

7.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import preprocessing
from sklearn import linear_model
from sklearn.metrics import accuracy_score
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier

df = pd.read_csv('data/fruit_data.csv', sep=',', encoding='utf-8')
```

```
X = np.array(df[['mass', 'width', 'height', 'color_score']])

fruit_codes = {'apple':0,  'lemon':1, 'mandarin':2, 'orange':3}
df['fruit_code'] = df['fruit_name'].map(fruit_codes)

y = np.array(df['fruit_code'])

scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

# LOGISTIC REGRESSION
model = linear_model.LogisticRegression(multi_class='multinomial', solver='newton-
cg')
model.fit(X_scaled, y)
ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
df['LRennuste'] = ennuste


# SUPPORT VECTOR CLASSIFIER
model = SVC()
model.fit(X_scaled, y)
ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
df['SVMennuste'] = ennuste


# SUPPORT VECTOR CLASSIFIER
model = KNeighborsClassifier()
model.fit(X_scaled, y)
ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
df['KNNennuste'] = ennuste
```

8 Tehtävä 8

Index	fruit_name	fruit_subtype	mass	width	height	olor_scor	Ennuste
0	apple	granny_smith	192	8.4	7.3	0.55	0
1	apple	granny_smith	180	8	6.8	0.59	0
2	apple	granny_smith	176	7.4	7.2	0.6	0
3	mandarin	mandarin	86	6.2	4.7	0.8	2
4	mandarin	mandarin	84	6	4.6	0.79	2
5	mandarin	mandarin	80	5.8	4.3	0.77	2
6	mandarin	mandarin	80	5.9	4.3	0.81	2
7	mandarin	mandarin	76	5.8	4	0.81	2
8	apple	braeburn	178	7.1	7.8	0.92	0
9	apple	braeburn	172	7.4	7	0.89	0
10	apple	braeburn	166	6.9	7.3	0.93	0
11	apple	braeburn	172	7.1	7.6	0.92	0
12	apple	braeburn	154	7	7.1	0.88	0
13	apple	golden_delicious	164	7.3	7.7	0.7	0
14	apple	golden_delicious	152	7.6	7.3	0.69	0
15	apple	golden_delicious	156	7.7	7.1	0.69	0

Osumatarkkuus = 100 % harjoitusdatalla, kun käytetään 20 opetuskertaa.

8.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import preprocessing
import tensorflow as tf
from tensorflow import keras

df = pd.read_csv('data/fruit_data.csv', sep=',', encoding='utf-8')

X = np.array(df[['mass', 'width', 'height', 'color_score']])

y = np.array(pd.get_dummies(df['fruit_name']))
```

```
# Skaalataan X arvot keskiarvoon 0 ja keskihajontaan 1
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)


model = keras.Sequential([
   # 1. piilotettu / input kerros
   keras.layers.Dense(30, activation=tf.nn.relu, input_shape=(X_scaled.shape[1],)),
   # 2. piilotetu kerros
   keras.layers.Dense(30, activation=tf.nn.relu),
   # output kerros -> 4 output luokkaa, softmax tulostaa ko. luokan
todennäköisyyden
   keras.layers.Dense(4, activation=tf.nn.softmax)
   ])

model.compile(optimizer=keras.optimizers.Adam(learning_rate=0.001),
          loss='categorical_crossentropy',
          metrics=['categorical_accuracy'])

model.fit(X_scaled, y, epochs=20, batch_size=1)

# hakee sarakkeesta ennusteen, jonka todennäköisyys suurin
ennuste = np.argmax(model.predict(X_scaled), axis=1)
df['Ennuste'] = ennustess
```

9 Tehtävä 9

Index	assengerI	Survived	LRennuste	vMennust	NNennust
165	166	1	0	0	1
331	332	0	1	0	0
212	213	0	0	0	0
764	765	0	0	0	0
849	850	1	1	1	1
160	161	0	0	0	0
788	789	1	0	0	0
8	9	1	1	1	1
593	594	0	1	1	1
147	148	0	1	0	0
641	642	1	1	1	1
521	522	0	0	0	0
815	816	0	1	0	0
796	797	1	1	1	1
547	548	1	0	0	0
92	93	0	0	0	0
860	861	0	0	0	0
657	658	0	1	1	1
121	122	0	0	0	0
564	565	0	1	1	1

Ennusteen keskivirhe logistisella regressiolla on 0.781.

Ennusteen keskivirhe SVM luokittelulla on 0.800.

Ennusteen keskivirhe K-Lähimmännaapurin luokittelulla on 0.781.

9.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import preprocessing
from sklearn import linear_model
from sklearn.metrics import accuracy_score
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier

df = pd.read_csv('data/Titanic.csv', sep=',', encoding='utf-8')

sex_B = {'male':0,  'female':1}
df['Sex_B'] = df['Sex'].map(sex_B)

df['Age'].fillna(-1, inplace=True)

embarked_B = {'C':0,  'S':1, 'Q':2}
df['Embarked_B'] = df['Embarked'].map(embarked_B)
df['Embarked_B'].fillna(-1, inplace=True)

#print(df['Pclass'].unique())
#for col in df:
 #   print(col)
  #  print(df[col].unique())

df_train = df.sample(n = 200, replace = False)
df_test = df.drop(df_train.index)

input_variables = ['Pclass', 'Sex_B', 'Age', 'SibSp', 'Parch', 'Embarked_B']

# LOGISTIC REGRESSION
# train
X = np.array(df_train[input_variables])
y = np.array(df_train['Survived'])
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

model = linear_model.LogisticRegression(multi_class='multinomial', solver='newton-
cg')
model.fit(X_scaled, y)

# test
X = np.array(df_test[input_variables])
y = np.array(df_test['Survived'])
```

```
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
df_test['LRennuste'] = ennuste


# SUPPORT VECTOR CLASSIFIER
# train
X = np.array(df_train[input_variables])
y = np.array(df_train['Survived'])
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

model = SVC()
model.fit(X_scaled, y)

# test
X = np.array(df_test[input_variables])
y = np.array(df_test['Survived'])
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
df_test['SVMennuste'] = ennuste


# SUPPORT VECTOR CLASSIFIER
# train
X = np.array(df_train[input_variables])
y = np.array(df_train['Survived'])
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

model = KNeighborsClassifier()
model.fit(X_scaled, y)

# test
X = np.array(df_test[input_variables])
y = np.array(df_test['Survived'])
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

ennuste = model.predict(X_scaled)
print(accuracy_score(y, ennuste))
```

```
df_test['KNNennuste'] = ennuste

results_fields = ['PassengerId', 'Survived', 'LRennuste', 'SVMennuste', 'KNNennuste']
df_results = df_test[results_fields].sample(20)
```

10 Tehtävä 10

Index	assengerI	Survived	Ennuste
669	670	1	1
40	41	0	1
63	64	0	0
232	233	0	0
536	537	0	1
141	142	1	0
57	58	0	0
100	101	0	0
212	213	0	0
14	15	0	0
98	99	1	1
585	586	1	1
97	98	1	0
433	434	0	0
421	422	0	0
5	6	0	0
504	505	1	1
571	572	1	1
275	276	1	1
862	863	1	1

Ennusteen tarkkuus on 0.855.

10.1 Lähdekoodi

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import preprocessing
import tensorflow as tf
from tensorflow import keras

df = pd.read_csv('data/Titanic.csv', sep=',', encoding='utf-8')

sex_B = {'male':0,  'female':1}
df['Sex_B'] = df['Sex'].map(sex_B)

df['Age'].fillna(-1, inplace=True)

embarked_B = {'C':0,  'S':1, 'Q':2}
df['Embarked_B'] = df['Embarked'].map(embarked_B)
df['Embarked_B'].fillna(-1, inplace=True)

df_train = df.sample(n = 200, replace = False)
df_test = df.drop(df_train.index)

input_variables = ['Pclass', 'Sex_B', 'Age', 'SibSp', 'Parch', 'Embarked_B']

# train
X = np.array(df_train[input_variables])
y = np.array(pd.get_dummies(df_train['Survived']))
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

model = keras.Sequential([
   # 1. piilotettu / input kerros
   keras.layers.Dense(30, activation=tf.nn.relu, input_shape=(X_scaled.shape[1],)),
   # 2. piilotetu kerros
   keras.layers.Dense(30, activation=tf.nn.relu),
   # output kerros -> 4 output luokkaa, softmax tulostaa ko. luokan
todennäköisyyden
   keras.layers.Dense(2, activation=tf.nn.softmax)
   ])

model.compile(optimizer=keras.optimizers.Adam(learning_rate=0.001),
          loss='categorical_crossentropy',
          metrics=['categorical_accuracy'])

model.fit(X_scaled, y, epochs=20, batch_size=1)
```

```
# test
X = np.array(df_test[input_variables])
#y = np.array(pd.get_dummies(df_test['Survived']))
scaler = preprocessing.StandardScaler()
X_scaled = scaler.fit_transform(X)

# hakee sarakkeesta ennusteen, jonka todennäköisyys suurin
ennuste = np.argmax(model.predict(X_scaled), axis=1)
df_test['Ennuste'] = ennuste

results_fields = ['PassengerId', 'Survived', 'Ennuste']
df_results = df_test[results_fields].sample(20)ss
```

11 Tehtävä 11

Sd

11.1 Lähdekoodi

sds

12 Tehtävä 12

Sd

12.1 Lähdekoodi

sds

13 Tehtävä 13

Sd

13.1 Lähdekoodi

sds

14 Tehtävä 14

Sd

14.1 Lähdekoodi

sds

15 Tehtävä 15

Sd

15.1 Lähdekoodi

sds

16 Tehtävä 16

Sd

16.1 Lähdekoodi

sds

17 Tehtävä 17

Sd

17.1 Lähdekoodi

sds

18 Tehtävä 18

Sd

18.1 Lähdekoodi

sds

19 Tehtävä 19

Sd

19.1 Lähdekoodi

sds

20 Tehtävä 20: Lähtevien asiakkaiden tunnistaminen

Oheisessa datassa (Telco.csv) on teleoperaattorin asiakastietokanta. Muuttuja churn=1 ilmaisee, että asiakas on lopettanut sopimuksen. Tehtäväsi on ennustaa kunkin asiakkaan ”churn”-kentän arvo käyttämällä input-muuttujina muiden kenttien arvoja. Jätä datasta 100 satunnaista asiakasta test-dataksi, ja vssalitse loput training-dataksi, jonka avulla muodostat haluamasi koneoppimismallin. Raportoi vastaukseesi seuraavat asiat:

• Käyttämäsi koneoppimismalli ja sen tarkkuus training- ja test-datassa.

• Huolehdi siitä, ettei malli ole liikaa ylisovitettu.

• Listaus 20 satunnaisesta test-datan asiakkaasta, jossa näkyy kunkin asiakkaan todellinen churn-arvo sekä mallisi ennuste (churn-riski numerona välillä 0-1)

Sd

20.1 Lähdekoodi

sds